

首届全国人工智能创新应用大赛

AI INNOVATION AND APPLICATION COMPETITION (AIAC)

总决赛

专题赛道：工业智能赛道

团队名：NeualNotWork


团队成员：

孙晨 华中科技大学

万宇森 华中科技大学

熊登锐 华中科技大学





1. 团队介绍
2. 背景分析
3. 实现方案
4. 赛题成果
5. 技术创新与工程化
6. 价值效益



人工智能创新应用大赛

AI INNOVATION AND APPLICATION COMPETITION (AIAC)



一、团队介绍

● 所属团队：华中科技大学机械学院 运筹与优化团队

指导老师：高亮教授 李新宇教授

技术积累：理论研究 (发表**ESI高被引论文10余篇**)、技术开发 (开发缺陷检测原型系统)、工程应用 (与**武钢、上达、歌尔**等多家企业开展合作)



参赛成员：

孙晨

比赛分工：

小目标检测



万宇森


半监督方法



熊登锐

缺陷检测模型






二、背景分析

- 热轧钢是工业制造的重要材料，广泛用于船舶、汽车、桥梁、航空等行业
- **表面缺陷**是热轧钢生产中最常见的质量问题，存在严重的安全隐患


传统检测技术




人工识别



涡流检测




电磁场检测




漏磁检测

- 使用场景受限
- 长期稳定性差
- 应用成本高
- 识别精度低


深度学习方法




CNN^[1]



GAN^[2]



Self-attention^[3]




Auto Encoder^[4]

- 使用范围广
- 工作效率稳定
- 成本低
- 识别精度高

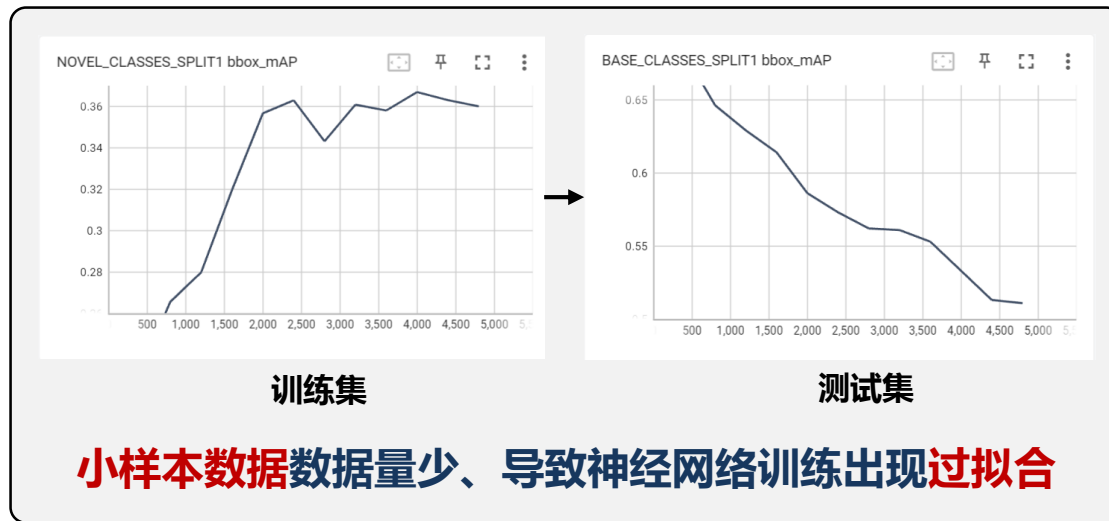

基于深度学习的表面缺陷检测技术成为当前的研究热门






二、背景分析

- 实际工业中，表面缺陷存在**样本数量少、类间尺度差异大**等现象
- **小样本、小目标数据**严重制约缺陷检测模型的精度



如何充分利用有限的缺陷数据实现高效的分析与检测
成为亟需解决的问题





三、实现方案


● 赛题回顾

赛题任务：缺陷的分类和定位

数据集构成：5类缺陷样本+正常样本

评价指标：mAP[@0.5:0.05:0.95]


标签	缺陷类别	图片数量	实例数量
1	氧化铁皮	396	567
2	翘纹系铁皮	363	364
3	精轧周期压痕迹	321	375
4	保护渣系夹渣	387	430
5	铁皮灰	356	576
总计	——	1823	2312
	正常	2066	——
总计	——	3889	2312




裂纹系翘皮



铁皮灰



氧化铁皮



精轧周期压痕




保护渣系夹渣



正常样本







三、实现方案


● 问题分析

- 难点1: **小目标**分辨率低, 特征信息少, 占总数据的**23.4%**, 误检率高
- 难点2: **目标尺度跨度大**, 且**尺度分布不均衡**, 多尺度并存, **漏检率高**
- 难点3: 检测框**高宽比多变**, 甚至出现极端高宽比, **漏检率高**



小目标分辨率低, 特征信息少, 数量多







三、实现方案

● 问题分析

- 难点1: **小目标分辨率低, 特征信息少, 占总数据的23.4%, 误检率高**
- 难点2: **目标尺度跨度大, 且尺度分布不均衡, 多尺度并存, 漏检率高**
- 难点3: **检测框高宽比多变, 甚至出现极端高宽比, 漏检率高**







三、实现方案

● 问题分析

- 难点1: **小目标**分辨率低, 特征信息少, 占总数据的**23.4%**, **误检率高**
- 难点2: **目标尺度跨度大**, 且**尺度分布不均衡**, **多尺度并存**, **漏检率高**
- 难点3: 检测框**高宽比多变**, 甚至出现**极端高宽比**, **漏检率高**




存在较多**极端高宽比**



目标尺度跨度大, **多尺度并存**





三、实现方案

问题难点

- 难点1: **小目标数量多**
- 难点2: **尺度分布不均衡**
- 难点3: **检测框高宽比多变**



总体思路

- 1) **两阶段缺陷检测算法**
- 2) **半监督训练框架**



关键技术


1. **锚框优化**
2. **基于Cascade RCNN的检测模型**
3. **基于Self-training的半监督算法**






三、实现方案

1. 基于聚类分析的锚框优化算法



拟合



- 回归收敛速度慢
- 漏检极端长宽比


锚框默认长宽比 [0.5, 1, 2]

原始长宽比分布

K-means聚类分析

取簇中心为锚框长宽比

多次重复取平均




[11, 2], [11, 18], [21, 19], [57, 8],
[154, 6], [57, 19], [258, 19]

[30, 4], [13, 18], [55, 8], [44, 19], [191,
8], [100, 20], [247, 20]

[12, 2], [10, 18], [17, 18], [107, 7], [41,
18], [137, 19], [267, 19]

.....




[0.125, 0.25, 0.5, 1.0, 2.0, 4.0, 8.0]



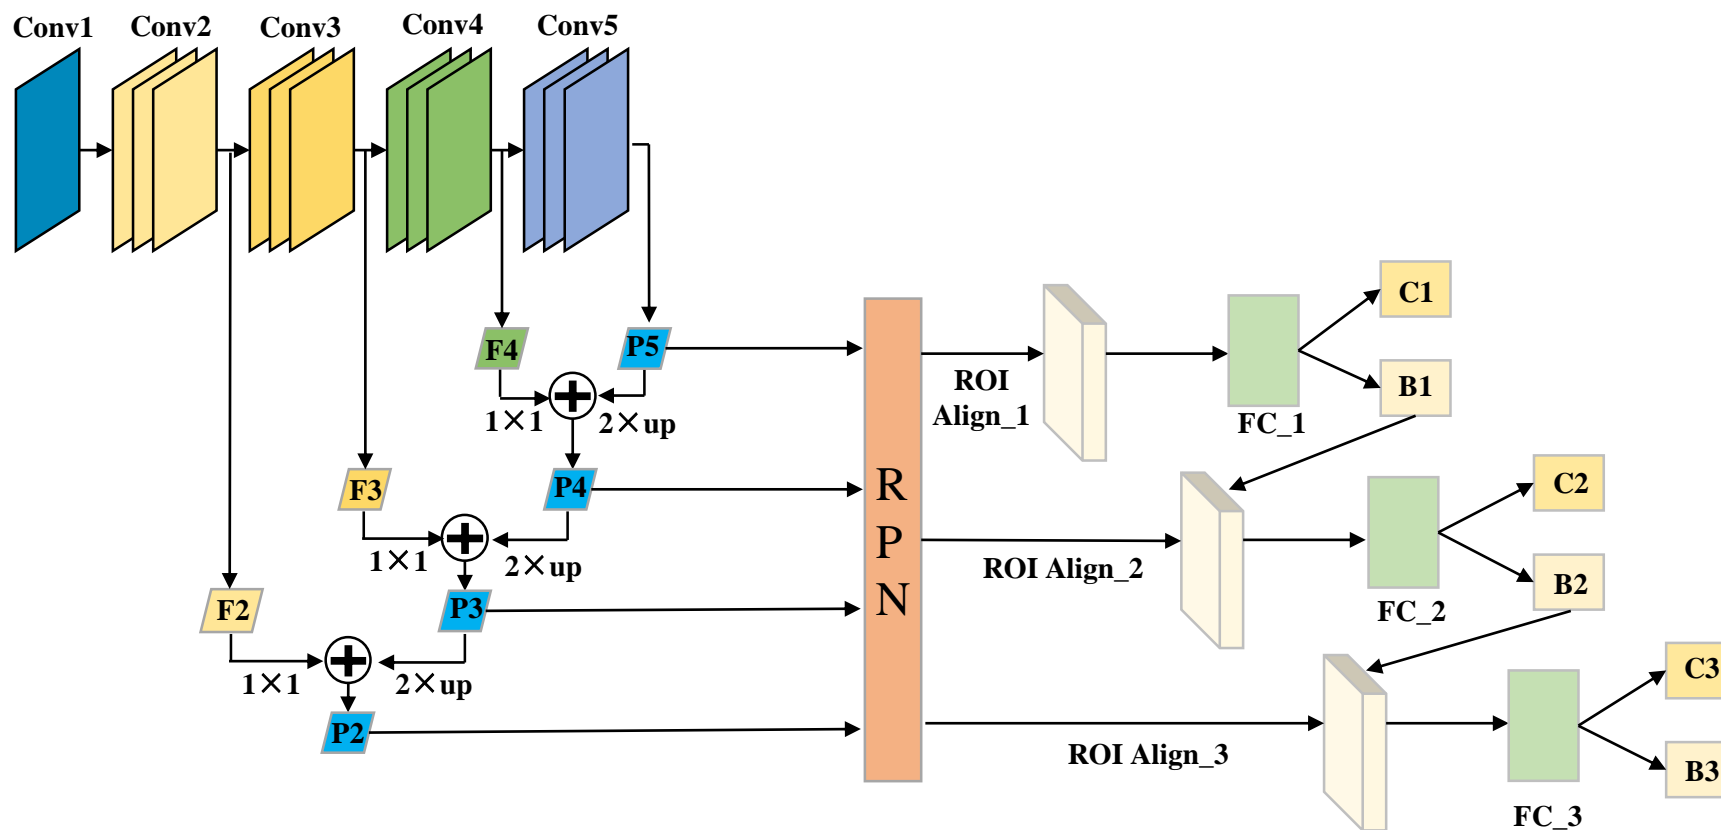
人工智能创新应用大赛


AI INNOVATION AND APPLICATION COMPETITION (AIAC)



三、实现方案

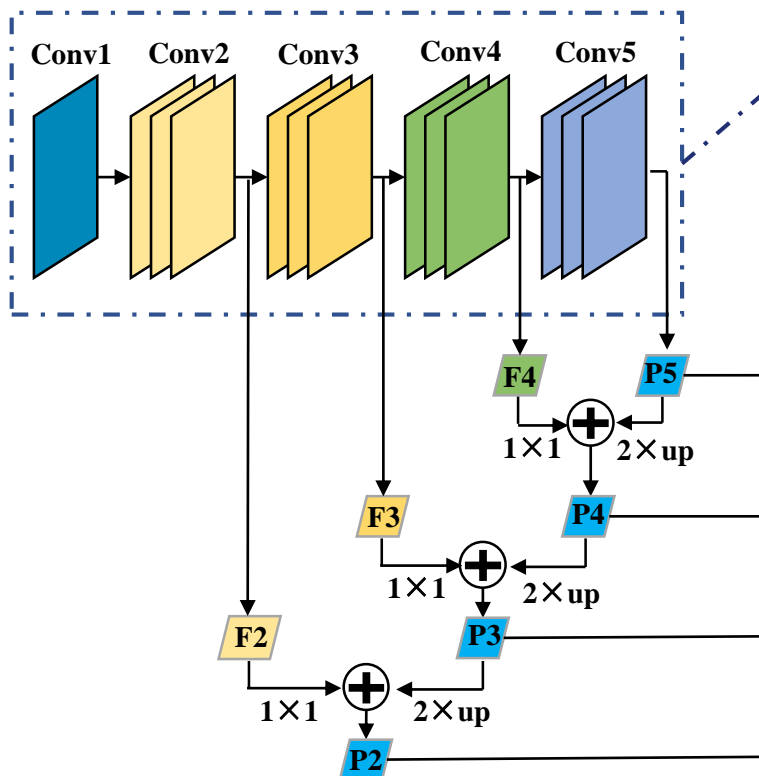
2. 检测模型: Cascade RCNN (ResNeXt101) + DCN + FPN





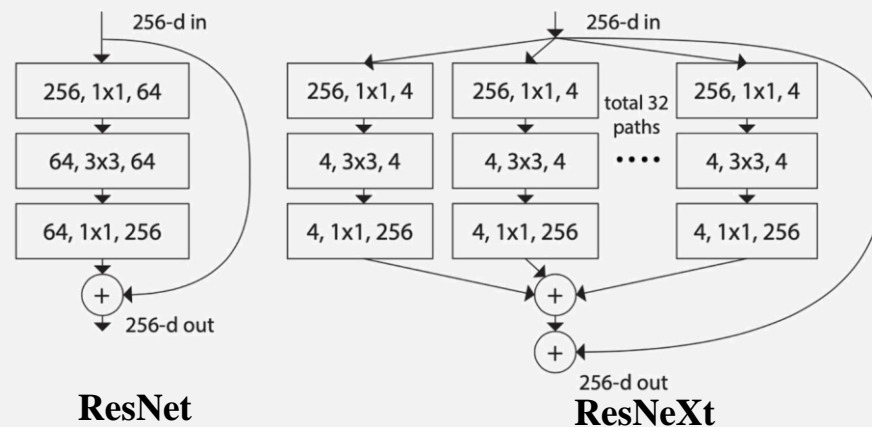
三、实现方案

2. 检测模型: Cascade RCNN (ResNeXt101) + DCN + FPN



① 骨干网络: ResNeXt-101 (ResNet-101)

- 使用**分组卷积**代替 3×3 卷积, 学习相关性特征, 剔除冗余
- 增加中间层的通道数 (64- \rightarrow 128), 参数量不变, **提升模型复杂度**



ROI Align_3

FC_3

C3

B3



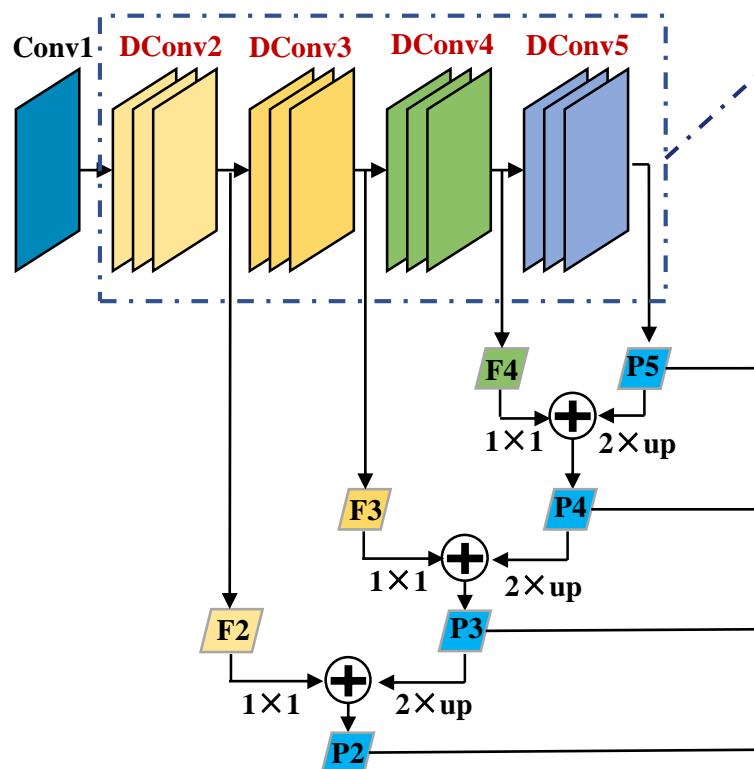
人工智能创新应用大赛

AI INNOVATION AND APPLICATION COMPETITION (AIAC)




三、实现方案

2. 检测模型: Cascade RCNN (ResNeXt101) + DCN + FPN



② 可变卷积 (Deformable Convolution)

- 对尺度或者感受野大小进行**自适应精确定位**
- 在卷积计算的过程中能够自动地计算每个点的偏移, 从而**让卷积的区域尽可能地集中在缺陷上**




ROI Align_3

FC_3

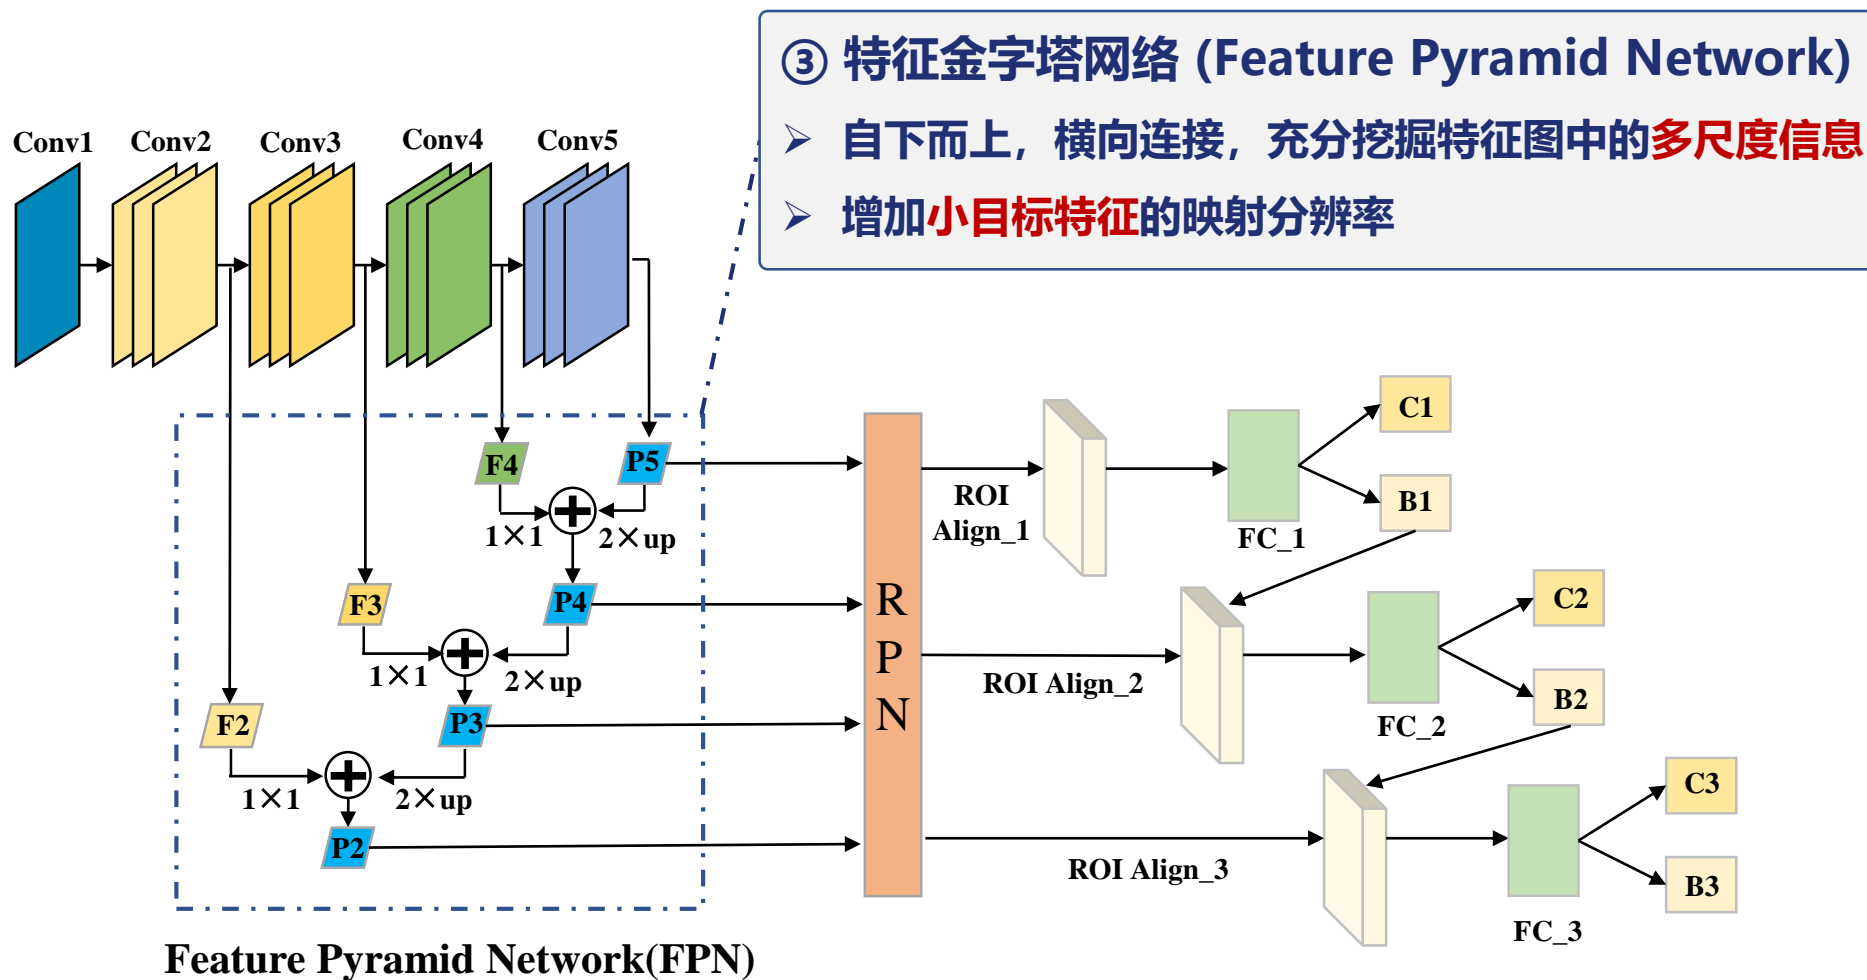
B3





三、实现方案

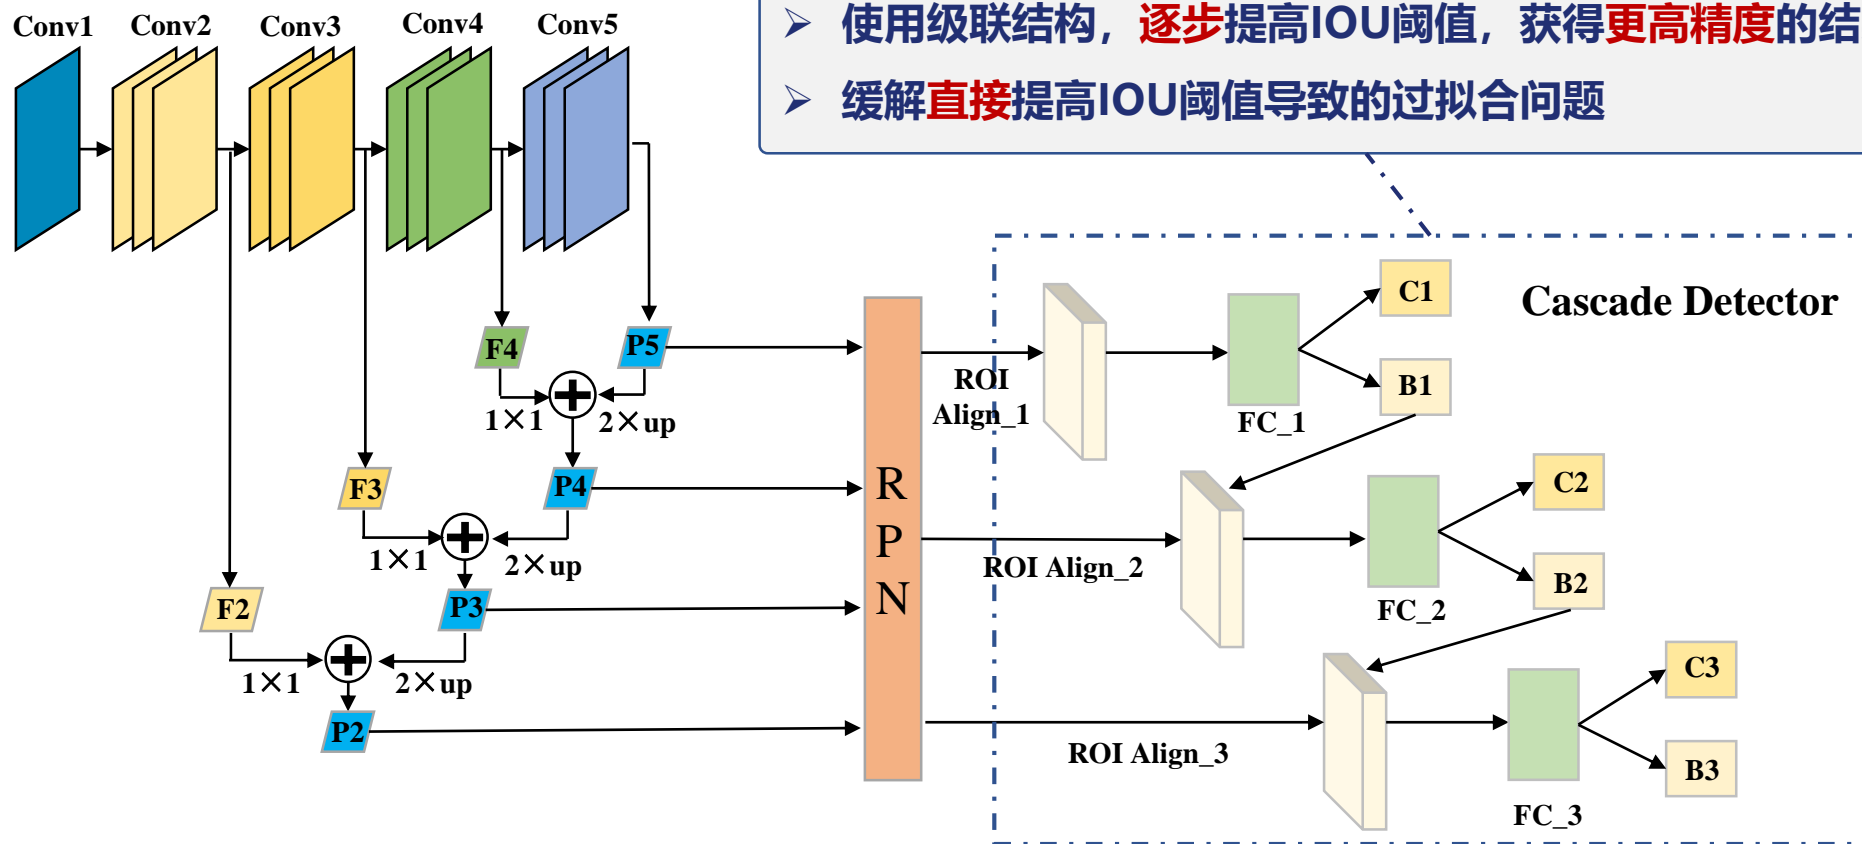
2. 检测模型: Cascade RCNN (ResNeXt101) + DCN + FPN





三、实现方案

2. 检测模型: Cascade RCNN (ResNeXt101) + DCN + FPN



④ 级联检测网络 (Cascade RCNN Detector)

- 使用级联结构，逐步提高IOU阈值，获得更高精度的结果
- 缓解直接提高IOU阈值导致的过拟合问题





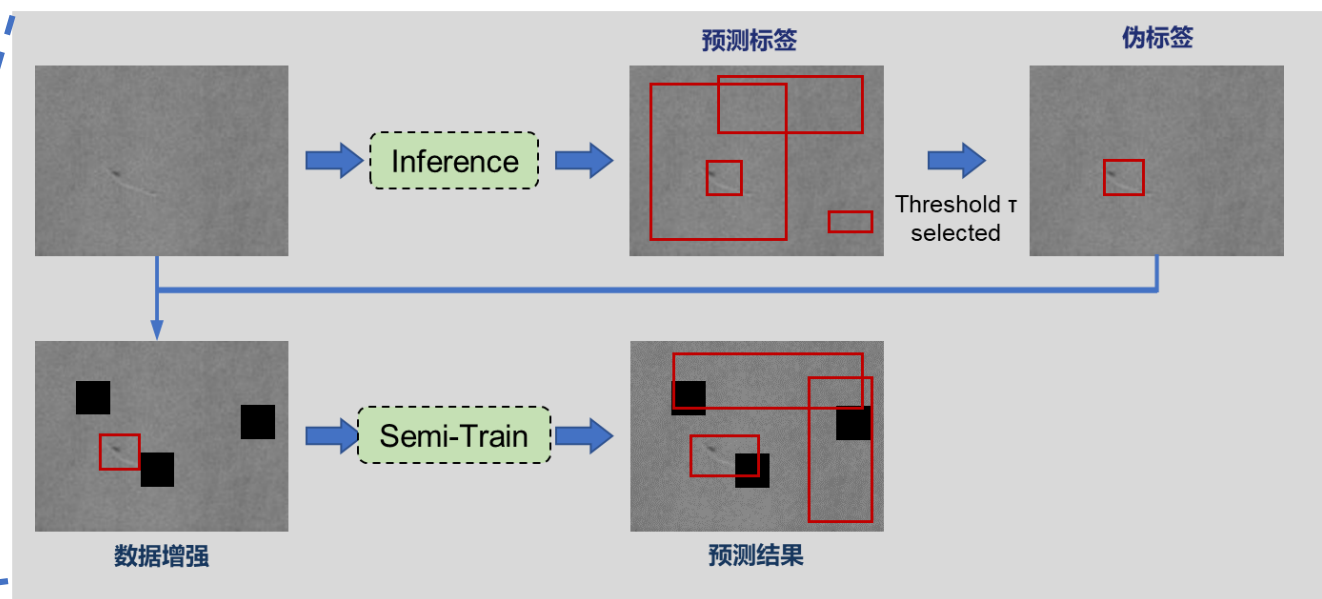
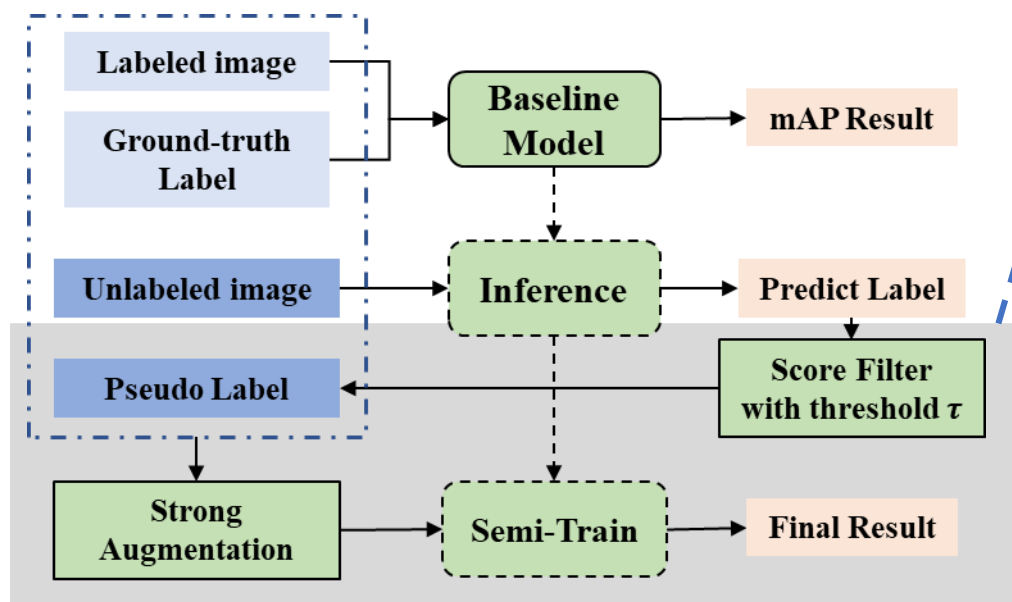
三、实现方案


3. 基于self-training的半监督算法

① 强数据增强算法：颜色变换、几何变换、Cutout、Mixup

② 半监督损失函数： $\ell = \ell_s(x_s, \mathbf{p}^*, \mathbf{t}^*) + \lambda_u \ell_u(\mathcal{A}(x_u, \mathbf{s}^*), \mathbf{q}^*)$

③ 超参数设置：threshold $\tau = 0.9$, hyperparameter $\lambda_u = 2$







三、实现方案

● 训练细节

- 缺陷目标的**空间对称性** —— 多角度随机翻转 → **增强模型的鲁棒性**
- 缺陷目标的**尺度不变性** —— 多尺度训练 → **丰富小目标的特征信息**
- 增强网络特征提取能力 —— COCO预训练权重 → **加快网络收敛**






四、赛题成果

● 结果比对


➤ Baseline模型

初赛线上评估结果



➤ 半监督框架

决赛线上评估结果



初赛：Rank 30 -> 决赛技术验证：Rank 8



人工智能创新应用大赛

AI INNOVATION AND APPLICATION COMPETITION (AIAC)



五、技术创新与工程化


● 技术创新

- 提出一种**两阶段缺陷检测算法**，有效解决了**小目标、尺度不均、高宽比变化范围**等问题
- 提出一种**半监督缺陷检测方法**，有效利用了**无标签数据**，极大提升了基础模型的精度

● 工程化

- 基于MMDetection**开源框架**，易于移植
- 所提方案为**单模型方法**，不需要多模型集成，节约计算资源







六、价值效益


- 所提缺陷检测方法适用于**多尺度、多类型**的工业缺陷场景
- 所提半监督框架可用于**小样本场景**，缓解了标注成本和模型精度的矛盾
- 所提半监督框架为**通用型方法**，可移植到**弱监督、无监督**等缺陷场景中

所提半监督方法在**小样本**下的效果对比



所提半监督方法在**弱监督缺陷模型**上的效果对比





参考文献

1. Wang Z, Jing J. Pixel-wise fabric defect detection by CNNs without labeled training data[J]. IEEE Access, 2020, 8: 161317-161325.
2. Hu C, Wang Y. An efficient convolutional neural network model based on object-level attention mechanism for casting defect detection on radiography images[J]. IEEE Transactions on Industrial Electronics, 2020, 67(12): 10922-10930.
3. Niu S, Li B, Wang X, et al. Defect image sample generation with GAN for improving defect recognition[J]. IEEE Transactions on Automation Science and Engineering, 2020, 17(3): 1611-1622.
4. Chow J K, Su Z, Wu J, et al. Anomaly detection of defects on concrete structures with the convolutional autoencoder[J]. Advanced Engineering Informatics, 2020, 45: 101105.
5. **Gao Y, Gao L, Li X, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition[J]. Robotics and Computer-Integrated Manufacturing, 2020, 61: 101825.**
6. **Yiping G, Xinyu L, Gao L. A Deep Lifelong Learning Method for Digital Twin-Driven Defect Recognition With Novel Classes[J]. Journal of Computing and Information Science in Engineering, 2021, 21(3): 031004.**
7. Cai Z, Vasconcelos N. Cascade r-cnn: Delving into high quality object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6154-6162.
8. Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
9. Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1492-1500.
10. DeVries T, Taylor G W. Improved regularization of convolutional neural networks with cutout[J]. arXiv preprint arXiv:1708.04552, 2017.
11. Sohn K, Zhang Z, Li C L, et al. A simple semi-supervised learning framework for object detection[J]. arXiv preprint arXiv:2005.04757, 2020.
12. Chen K, Wang J, Pang J, et al. MMDetection: Open mmlab detection toolbox and benchmark[J]. arXiv preprint arXiv:1906.07155, 2019.

.....





谢 谢！

敬请各位专家批评指正！